

Web Crawlers Crawling policies

Pertemuan 9





DEFENISI

- Web crawler adalah sebuah bot yang mencari dan mengindeks konten di World Wide Web.
- Alasan disebut web crawler karena crawling adalah istilah teknis yang mewakili proses pengaksesan website secara otomatis dan memperoleh data melalui program software tertentu.
- Pada dasarnya, fungsi web crawler bertanggung jawab untuk memahami konten di halaman web sehingga mereka dapat menampilkan hasil pencarian yang diinisiasi oleh pengguna melalui search engine.

BOT

- Bot yang juga sering disebut web spider dioperasikan oleh search engine dengan algoritma mereka sendiri.
- Dengan menerapkan algoritma pencarian data yang crawler kumpulkan, search engine selanjutnya menghasilkan daftar laman web yang muncul setelah pengguna mengetik penelusuran ke Google.
- Selain itu, bot akan mencari (crawl) dan mengkategorikan semua halaman web yang bisa ditemukan di internet untuk selanjutnya diindeks.




Indexing

- Indexing bisa diibaratkan seperti membuat arsip atau daftar katalog kartu untuk internet yang merupakan hasil dari proses crawling.
- Indexing sebagian besar berfokus pada teks yang muncul di halaman dan metadata atau data tentang halaman yang tidak bisa pengguna lihat dalam halaman web.
- Ketika sebagian besar search engine mengindex halaman, mereka menambahkan semua kata pada halaman ke index.
- Ketika pengguna mencari informasi menggunakan kata-kata tertentu, maka search engine akan menelusuri indeks semua halaman di mana kata-kata itu kemungkinan muncul lalu memilih yang paling relevan.



CARA KERJA WEB CRAWLER



JENIS WEB CRAWLER

01

General-Purpose web crawler
(Web Crawler untuk umum)

02

Focused web crawler
(Web crawler terfokus)

03

Incremental web crawler
(Web crawler tambahan)

04

Parallel web crawler
(Web crawler paralele)

05

Hidden web crawler
(Web crawler tersembunyi)

JENIS WEB CRAWLER

GENERAL-PURPOSE WEB CRAWLER

- Merupakan jenis web crawler pertama yang dikodekan.
- Tujuan umum mengindeks sebanyak mungkin halaman di web. Dengan demikian, web crawler ini menelusuri cadangan data yang sangat besar untuk menjangkau sebanyak mungkin internet.

SECONDARY OBJECTIVES

Web crawler yang terfokus hanya mengkhususkan pada topik tertentu. Dengan demikian, hanya terbatas pada meta tag tertentu. Contoh, Web crawler yang hanya menelusuri situs web atau blog yang berisi resep makanan dan membuat katalognya.

JENIS WEB CRAWLER

INCREMENTAL WEB CRAWLER

Web crawler tambahan berfokus pada pelacakan perubahan di seluruh halaman web yang sudah ada atau yang sudah diindeks. Dengan cara mengunjungi halaman web dan situs serta memperbarui konten untuk melacak perubahan baru pada halaman web.

Web crawler tambahan memiliki tiga modul utama.

- Modul peringkat
- Modul pembaruan, dan
- Modul perayapan.

Selain itu, menggunakan struktur data antrian prioritas untuk mengimplementasikan fungsionalitas penelusuran tambahan.

PARALLEL WEB CRAWLER

Web crawler jenis ini menjalankan beberapa proses secara paralel, bukan hanya satu proses.

Tujuan dari web crawler paralel adalah untuk mengoptimalkan proses penelusuran dengan memaksimalkan kecepatan unduhan tetapi meminimalkan overhead paralelisasi. Hal ini pada akhirnya membantu dalam mengurai internet secara keseluruhan, yang sangat besar.

JENIS WEB CRAWLER

HIDDEN WEB CRAWLER

Web crawler tersembunyi adalah satu-satunya jenis penelusuran web yang dapat mengakses deep web dan membantu menelusuri halaman web yang tersembunyi menggunakan kata kunci atau registrasi pengguna yang spesifik

Contoh web crawler



1 Googlebot

Googlebot adalah web crawler yang paling banyak digunakan saat ini. Seperti namanya, web crawler ini adalah milik Google. Googlebot mengumpulkan berbagai dokumen yang ada di sebuah website untuk membuat indeks yang dapat dicari oleh search engine Google. Web crawler yang satu ini merujuk pada dua jenis web crawler, yaitu desktop crawler dan mobile crawler.

2 HTTrack

HTTrack adalah web crawler yang bersifat open source. User bisa men-download situs world wide web (www) dari internet ke komputer pribadi sehingga bisa melihatnya secara offline. Jika sudah men-download konten situs tersebut, kamu bisa membukanya melalui browser-mu tanpa koneksi internet.

3 Cyotek Webcopy

Cyotek Webcopy dapat digunakan untuk men-download situs dari internet ke komputermu. Salah satu kelebihan web crawler ini adalah memungkinkan penggunaanya memilih bagian yang ingin di-download. Jadi, kamu bisa memilih apakah ingin men-download semua bagian situs, foto tertentu, dan sebagainya.

4 Webhose

Webhose adalah web crawler yang dapat mengubah konten website yang tidak terstruktur menjadi data feeds yang dapat dibaca oleh mesin. Data feeds yang dimaksud dapat mencakup banyak sumber data, seperti diskusi online, situs berita, dan lainnya.

KEBIJAKAN WEB CRAWLER

- Selection policy (yang menyatakan halaman untuk diunduh)
- Re-visit policy (yang menyatakan kapan memeriksa perubahan pada halaman)
- Politeness policy (yang menyatakan bagaimana cara untuk menghindari Overloading Web sites)
- Parallelization policy (yang menyatakan bagaimana mengoordinasikan web crawler terdistribusi)

SELECTION POLICY

Sebuah studi tahun 2009 menunjukkan bahkan indeks mesin pencari skala besar tidak lebih dari 40-70% dari web yang dapat diindeks. Penelitian sebelumnya oleh Steve Lawrence dan Lee Giles menunjukkan bahwa tidak ada mesin pencari yang mengindeks lebih dari 16% dari Web pada tahun 1999. Merancang kebijakan pemilihan yang baik memiliki kesulitan tambahan: ia harus bekerja dengan informasi parsial, karena set lengkap halaman Web tidak dikenal selama perayapan. Selection Policy Meliputi

- Restricting followed links (Membatasi tautan yang diikuti)
- URL normalization (Normalisasi URL)
- Path-ascending crawling (Perayapan jalur-naik)
- Focused crawling (Perayapan terfokus)

RE-VISIT POLICY

Web memiliki sifat yang sangat dinamis, dan merayapi sebagian kecil dari Web dapat memakan waktu berminggu-minggu atau berbulan-bulan. Pada saat penelusuran Web telah menyelesaikan penelusurannya, banyak peristiwa dapat terjadi, termasuk pembuatan, pembaruan, dan penghapusan. Dari sudut pandang mesin pencari, ada biaya yang terkait dengan tidak mendeteksi suatu peristiwa, dan dengan demikian memiliki salinan sumber daya yang sudah usang. Fungsi biaya yang paling sering digunakan adalah Freshness dan Age.

POLITENESS POLICY

Crawler dapat mengambil data jauh lebih cepat dan lebih dalam dari pada pencari manusia, sehingga mereka dapat memiliki dampak yang melumpuhkan pada kinerja suatu situs. Seperti dicatat oleh Koster, penggunaan crawler Web berguna untuk sejumlah tugas, tetapi disertai dengan harga untuk masyarakat umum. Biaya Menggunakan Crawler Web Meliputi :

- Sumber Daya Jaringan Karena crawler membutuhkan bandwidth yang besar dan beroperasi dengan tingkat paralelisme yang tinggi selama periode waktu yang lama
- Server Overload Terutama jika frekuensi akses ke server yang diberikan terlalu tinggi
- Crawler Yang Ditulis Dengan Buruk Yang dapat membuat crash server atau router, atau halaman unduh yang tidak dapat mereka tangani
- Penelusur Pribadi Jika digunakan oleh terlalu banyak pengguna, dapat mengganggu jaringan dan server Web.

PARALLELIZATION POLICY

Crawler Parallel adalah Crawler yang menjalankan banyak proses secara paralel. Tujuannya adalah untuk memaksimalkan kecepatan unduhan sambil meminimalkan overhead dari paralelisasi dan untuk menghindari unduhan berulang pada halaman yang sama

LATIHAN

- Jelaskan apa yang dimaksud dengan web crawler
- Jelaskan cara kerja web crawler
- Sebutkan dan jelaskan contoh-contoh web crawler lainnya, berikut dengan cara kerjanya
- Jelaskan kelebihan dan kekurangan web crawler

